FORMULACIÓN DE UNA PROPUESTA DE PROYECTO DE TESINA
para optar al grado de
Magíster en Tecnologías de la Información

I. IDENTIFICACIÓN Y RESUMEN DEL PROYECTO

1.1 Identificación del proponente y candidato a magíster

Nombre del estudiante	Francisco Javier Peñailillo San Martin
RUT	18.095.746-4
Ciudad y región de residencia	Santiago, Region Metropolitana
Ciudad y región de trabajo	Santiago, Region Metropolitana
E-mail y teléfono de contacto	Fpenailillo@usm.cl +56968603885
Fecha de ingreso al MTI	2024

1.2 Identificación del Proyecto de tesina propuesto

Título del proyecto	Sistema Inteligente de Predicción de Riesgo de Avalanchas para Chile: Boletines de Seguridad Zonales mediante Coordinación de Agentes de IA Especializados
Área principal de TI	Datos e IA
Profesor guía propuesto	Dr. Mauricio Solar
Organización/empresa a la que se vincula el proyecto	
Persona y cargo del contacto	
E-mail y teléfono del contacto	

.....
FIRMA

1.3 Resumen del Proyecto de tesina propuesto

En Chile, miles de personas se enfrentan al riesgo de avalanchas sin contar con sistemas de predicción avanzados como en países desarrollados, donde se alcanzan precisiones del 74–78% con hasta 72 horas de anticipación. Actualmente, el monitoreo y control de riesgos en el país depende de patrullajes manuales, lo que limita la cobertura y la capacidad de respuesta.

Se propone el desarrollo del primer sistema nacional inteligente de predicción de riesgos de avalanchas, basado en una arquitectura de sistemas multi-agentes. Cuatro agentes de IA especializados procesarán datos topográficos, datos meteorológicos de alta frecuencia, imágenes satelitales y conocimiento experto extraído de relatos de montañistas. El sistema generará pronósticos automatizados según la Escala Europea de Peligro de Aludes, con boletines zonales de 24 a 72 horas.

La validación se realizará mediante comparación con datos históricos del Instituto Suizo SLF, pronósticos manuales de Snowlab Chile y pruebas en terreno durante el invierno de 2026. El objetivo es alcanzar una precisión superior al 75% en la predicción del riesgo de avalancha en las zonas de estudio. El sistema se implementará sobre infraestructura cloud escalable que permite cobertura territorial amplia con costos operacionales mínimos, posicionando a Chile como pionero hemisférico en aplicación de IA para gestión de riesgos naturales en montaña.

1.4 Palabras claves

Sistemas Distribuidos, Deep Learning, Sistemas multi-agente, Análisis predictivo de series de tiempo, Predicción de riesgo de avalanchas.

II. FORMULACION GENERAL DEL PROYECTO

Chile enfrenta un vacío crítico en infraestructura predictiva de avalanchas. Mientras sistemas operacionales en países desarrollados alcanzan 74–78% de precisión con 72 horas de anticipación (Instituto Suizo SLF), el monitoreo nacional depende exclusivamente de patrullajes manuales en centros de ski, dejando sin cobertura gran parte del territorio cordillerano donde miles de personas realizan actividades de montaña anualmente.

Esta ausencia de sistemas predictivos afecta especialmente a comunidades locales de pueblos de montaña, donde residentes permanentes, trabajadores de centros de ski, guardaparques, operadores turísticos y personal de infraestructura crítica (caminos, electricidad, comunicaciones) enfrentan riesgo constante sin acceso a información oportuna. Poblaciones como Farellones, Valle Nevado, Portillo, y decenas de asentamientos cordilleranos menores dependen de caminos de acceso único frecuentemente amenazados por avalanchas, generando aislamiento prolongado, pérdida económica por suspensión de actividades turísticas, y riesgo para la seguridad de habitantes permanentes que carecen de alternativas de evacuación rápida. El impacto trasciende lo recreacional: familias enteras viven y trabajan en estas zonas sin ninguna herramienta predictiva que les permita anticipar períodos de alto riesgo.

Snowlab Chile, iniciativa privada desde 2024, genera pronósticos manuales semanales únicamente para La Parva mediante profesionales certificados. Si bien representa la primera aproximación sistemática nacional, presenta limitaciones críticas: escalabilidad territorial nula (cobertura $\sim 5km^2$), capacidad operacional limitada (1 profesional → 1-2 zonas/día), costo operacional elevado, e inconsistencia metodológica inter-regional. Esta dependencia de análisis manual restringe la posibilidad de establecer un sistema nacional de cobertura comprehensiva.

Definición Técnica del Problema

El problema se define como predicción multimodal de series temporales en ambiente geoespacial específico a gran escala, con tres subproblemas interrelacionados:

- Integración de datos heterogéneos: Fusionar fuentes con diferentes resoluciones espaciales (SRTM 30m, satelital 10-250m), temporales (observaciones cada 15-30 minutos vs. predicciones 10 días) y naturaleza (estructurados: meteorología desde Google Weather API; semi-estructurados: relatos; geoespaciales: DEM). Requiere sincronización temporal, normalización espacial y extracción de features desde fuentes no estructuradas.
- Modelado predictivo con datos escasos: Las avalanchas son eventos raros en territorio extenso, generando datasets altamente desbalanceados. Chile carece de registros históricos sistemáticos, requiriendo estrategias de transfer learning desde regiones con datos abundantes (Suiza, Canadá) hacia condiciones chilenas únicas (clima continental, influencia ENSO, capas débiles persistentes).
- Pronósticos explicables y zonales: Los usuarios (guardaparques, operadores, autoridades) requieren comprensión de factores causales y zonificación espacial precisa, demandando capacidades de explicabilidad y generación automatizada de boletines en lenguaje natural.

Estrategia de Solución Propuesta

La solución adopta especialización coordinada mediante arquitectura multi-agente serverles sobre Google Cloud Platform,. Los cuatro agentes especializados son:

Agente 1 - Análisis Topográfico-Nival: Procesa datos SRTM mediante Google Earth Engine para identificar zonas con pendientes críticas (30-45°) y segmentación altitudinal. Aplica Physics-Informed Neural Networks (PINNs) para modelar evolución del manto considerando variación térmica por altitud, incorporando ecuaciones de conservación de energía y mecánica de materiales. Output: mapa de susceptibilidad base + estado estimado del manto estratificado.

Agente 2 - Monitoreo Satelital: Emplea técnicas de análisis multimodal para procesamiento de imágenes nivales en series temporales Sentinel-2/Modis integradas vía Google Earth Engine. Combina bandas espectrales (visible, infrarrojo cercano y térmico) para detectar cambios en cobertura nival y características superficiales indicativas de inestabilidad mediante análisis de anomalías espaciotemporales [17]. Output: anomalías detectadas con nivel de alerta.

Agente 3 - Predicción Meteorológica: Integra datos meteorológicos desde Google Weather API con tres resoluciones temporales: (1) condiciones actuales con actualización cada hora, (2) pronósticos proyectados por horas hasta 240 horas futuras, y (3) pronósticos proyectados por días hasta 10 días futuros. Variables procesadas en todas las resoluciones: temperatura y sensación térmica, punto de rocío, índice de calor, precipitación (probabilidad y acumulación), viento (velocidad, dirección, sensación de viento), presión atmosférica, humedad relativa, visibilidad, índice UV, cobertura de nubes. Output: series temporales meteorológicas multi-resolución y multi-horizonte estratificadas por altitud, permitiendo análisis tanto de condiciones actuales como proyecciones de corto (horario) y mediano (diario) plazo.

Agente 4 - Integración de Riesgos: Fusiona outputs anteriores con patrones históricos extraídos de ~4000+ relatos de montañistas mediante NLP [19] para clasificación según Escala Europea de Peligro de Aludes (5 niveles). Extrae factores explicativos y genera boletines automatizados en lenguaje natural siguiendo estructura SLF/AEMET. Output: pronósticos zonales 24h/48h/72h con niveles de confianza y recomendaciones.

Los agentes operan en pipeline secuencial con retroalimentación: el agente topográfico identifica zonas susceptibles (constante), agentes satelital y meteorológico proporcionan condiciones dinámicas actualizadas continuamente, y el agente integrador sintetiza información produciendo pronósticos zonales automatizados.

Contribución y Originalidad

No existe implementación documentada de arquitectura multi-agente serverless para predicción de avalanchas que integre: (1) análisis topográfico automatizado vía Google Earth Engine, (2) monitoreo satelital, (3) predicción meteorológica mediante integración continua con Google Weather API, (4) extracción de conocimiento comunitario mediante NLP, y (5) arquitectura event-driven escalable con costos operacionales mínimos. La combinación de estas cinco tecnologías especializadas, junto con transfer learning desde datos suizos hacia condiciones andinas chilenas, representa la principal innovación del proyecto. El sistema será el primero de cobertura nacional en Latinoamérica, con potencial de replicación en otros países andinos (Perú, Argentina, Bolivia) que enfrentan problemáticas similares.

2.2 Marco teórico y estado del arte

Marco Teórico

Ciencia de Avalanchas: La formación responde a interacción compleja de terreno, manto nival y meteorología. En Chile, condiciones críticas se concentran en pendientes 30-45° y altitudes 2.500-3.500 msnm donde la isoterma 0°C fluctúa generando ciclos de derretimiento-recongelamiento. La estabilidad del manto depende de formación de capas débiles persistentes bajo gradientes térmicos intensos. Los aludes se clasifican en: nieve reciente (densidad <200 kg/m^3), placa (200-400 kg/m^3) y nieve húmeda (350-500 kg/m^3).

Sistemas Multi-Agente Serverless: Paradigma arquitectural donde agentes autónomos especializados colaboran mediante comunicación asíncrona event-driven. La especialización permite expertise focalizado mientras la coordinación habilita síntesis de información complementaria [20]. La arquitectura serverless (Cloud Functions + Pub/Sub) proporciona escalabilidad automática, pago por uso, y tolerancia a fallos mediante Dead Letter Queues, ideal para integrar fuentes heterogéneas con diferentes frecuencias de actualización.

Physics-Informed Neural Networks (PINNs): Integran principios físicos como restricciones en función de pérdida de redes neuronales. Para modelado nival, incorporan ecuaciones de conservación de energía y mecánica de materiales, reduciendo requerimientos de datos empíricos mientras mantienen consistencia física. Demuestran efectividad en procesos hidro-glaciológicos donde datos son escasos pero física es bien comprendida, como en modelado de flujo de hielo glaciar [15] y estimación de espesor glaciar en regiones con datos limitados [16].

Google Weather API: Servicio de Google Maps Platform que proporciona datos meteorológicos con tres resoluciones temporales: (1) condiciones actuales con actualización cada hora, (2) pronósticos proyectados por horas hasta 240 horas futuras para planificación de corto plazo, y (3) pronósticos proyectados por días hasta 10 días futuros para planificación de mediano plazo. Los modelos combinan IA de Google DeepMind con sistemas tradicionales de predicción numérica, proporcionando datos hiperlocales monitoreados continuamente para precisión. Cobertura global excepto Japón, Corea y territorios prohibidos. La triple resolución temporal permite análisis tanto de condiciones inmediatas como tendencias de corto y mediano plazo, crítico para modelar ventanas de riesgo de avalanchas que pueden desarrollarse en escalas temporales múltiples.

Transfer Learning: Ante carencia de registros chilenos sistemáticos, permite aprovechar conocimiento desde dominios ricos en datos (Swiss SLF: >80 años de experiencia, bases desde 1936) mediante fine-tuning. La hipótesis fundamental es que patrones de bajo nivel (texturas nivales, firmas espectrales, relaciones meteorología-estabilidad) son transferibles inter-regionalmente. Estudios recientes demuestran mejoras significativas en precisión al aplicar transfer learning desde regiones con datos abundantes hacia regiones data-scarce [21].

Estado del Arte

Sistemas Operacionales Internacionales: El Instituto Suizo SLF alcanza 74-78% de precisión equiparable a pronosticadores expertos humanos, operando con 72h de anticipación mediante random forests sobre 50+ años de datos. Recientemente, SLF integró operacionalmente su primer modelo ML (RAvaFcast) alcanzando ~70% de concordancia en pronósticos 24h [22][23], marcando un hito en predicción automatizada. Servicios en Noruega han demostrado 76% de precisión usando modelos estadísticos con datos de reanálisis en regiones con observaciones limitadas [24]. Sin embargo, estos sistemas presentan enfoque monolítico sin modularidad, dependencia de infraestructura observacional costosa (>500 estaciones), y adaptación regional limitada. Canadian Avalanche Centre emplea combinación similar de modelos numéricos con validación humana.

Contexto Nacional - Snowlab Chile: Desde 2024 opera el primer servicio estructurado mediante pronósticos semanales por profesionales certificados con observaciones de campo sistemáticas en

La Parva. Representa un avance significativo al establecer metodología rigurosa y credibilidad con stakeholders. Sin embargo, enfrenta limitaciones críticas de escalabilidad: cobertura territorial nula más allá de ~5km^2, costo operacional elevado, inconsistencia inter-regional potencial, y capacidad limitada inherente al modelo manual (1 profesional → 1-2 zonas/día máximo). La propuesta no busca reemplazar el expertise humano de Snowlab sino complementarlo tecnológicamente y extenderlo a regiones sin cobertura, estableciendo infraestructura nacional base.

Monitoreo Satelital con Google Earth Engine: Investigaciones recientes demuestran la capacidad de Google Earth Engine para procesamiento a gran escala de imágenes Sentinel-2, Landsat y MODIS para monitoreo nival en regiones montañosas [18]. Estos estudios validan la viabilidad técnica de pipelines automatizados para detección de cobertura nival, extracción de métricas de estacionalidad y análisis de tendencias temporales sobre regiones extensas, proporcionando base metodológica para el componente de monitoreo satelital del sistema propuesto. Estudios específicos en los Andes Chilenos documentan tendencias de cobertura nival durante 39 años mediante Landsat [26], confirmando disponibilidad de datos históricos para entrenamiento y validación.

Brecha Identificada: No existe implementación de arquitectura multi-agente serverless para predicción de avalanchas que integre análisis topográfico automatizado, análisis multimodal para monitoreo satelital, integración continua con Google Weather API, extracción de conocimiento comunitario mediante NLP, y arquitectura basada en eventos escalable de bajo costo. Si bien trabajos recientes combinan simulaciones de estabilidad de manto nival con machine learning logrando mejoras predictivas significativas [25], estos enfoques siguen siendo monolíticos y computacionalmente costosos. La combinación de estas cinco tecnologías especializadas en arquitectura multi-agente serverless representa la principal contribución del proyecto.

2.3 Diseño de la investigación

Objetivos Generales

Desarrollar e implementar el primer sistema nacional de predicción automatizada de avalanchas para Chile mediante arquitectura multi-agente serverless que integra análisis topográfico, monitoreo satelital integración continua con Google Weather API, y conocimiento experto comunitario, generando pronósticos zonales según Escala Europea de Peligro de Aludes con precisión ≥75% en horizontes 24-72h, validado mediante comparación con datos históricos internacionales, pronósticos manuales chilenos, y despliegue operacional piloto.

Hipótesis de Investigación

H1 (Principal): Un sistema multi-agente serverless que integra análisis topográfico automatizado (SRTM), monitoreo satelital (Vision Transformers), integración continua con Google Weather API y conocimiento experto extraído de relatos (NLP), puede generar pronósticos de riesgo de avalanchas para Chile clasificados según la Escala Europea de Peligro de Aludes (5 niveles) con precisión superior al 75% (F1-score macro) en horizontes de 24-72 horas, equiparando el desempeño de sistemas operacionales de países desarrollados (Suiza SLF: 74-78%).

H2 (Conocimiento Experto): La incorporación de conocimiento experto extraído de relatos de montañistas chilenos mediante técnicas de NLP mejora significativamente (>5 puntos porcentuales en F1-score) la precisión de predicción comparado con sistemas basados únicamente en datos observacionales estructurados.

H3 (Transfer Learning): Un modelo entrenado mediante transfer learning desde datos históricos del Instituto Suizo SLF (>20 años) y fine-tuned con datos chilenos limitados, supera el desempeño de un modelo entrenado exclusivamente con datos chilenos escasos.

H4 (Equiparación Humana): El sistema automatizado alcanza concordancia ≥75% con pronósticos manuales generados por profesionales certificados (Snowlab Chile) en La Parva, demostrando capacidad de replicar juicio experto humano.

Variables de Investigación

Variables Independientes: (1) Arquitectura del sistema (multi-agente serverless vs. monolítica), (2) Fuentes de datos integradas (topografía, satelital, meteorología Google Weather API, relatos NLP - presente/ausente), (3) Horizonte temporal de predicción (24h, 48h, 72h), (4) Estrategia de entrenamiento (transfer learning vs. desde cero), (5) Zona geográfica (sectores cordilleranos 33°-41°S).

Variables Dependientes: (1) Métricas de precisión: F1-score macro por nivel EAWS (1-Débil a 5-Muy Fuerte), Precision, Recall, accuracy por dimensión (estabilidad, probabilidad, distribución/tamaño), AUC-ROC, matriz de confusión 5x5; (2) Desempeño temporal: degradación por horizonte (24h→72h), lead time efectivo; (3) Cobertura territorial: porcentaje de zonas con pronósticos, resolución espacial; (4) Explicabilidad: completitud de factores identificados, concordancia con estándares; (5) Costos operacionales: costo por ubicación monitoreada, escalabilidad económica.

Metodología de Validación

Fase 1 - Benchmarking Retrospectivo (Datos Suizos): Validación con datos históricos del Instituto Suizo SLF (1999-2024) para demostrar que la arquitectura alcanza desempeño equiparable a sistemas establecidos. División temporal: entrenamiento 1999-2019, validación 2020-2022, test 2023-2024. Criterio de éxito: F1-score macro ≥0.75 en 24h, ≥0.72 en 48h, ≥0.68 en 72h; accuracy en niveles críticos (3-Notable/4-Fuerte/5-Muy Fuerte) ≥0.80.

Fase 2 - Transfer Learning y Validación Chilena: Construcción de dataset chileno con topografía SRTM (33°-41°S), meteorología histórica desde Google Weather API, avalanchas documentadas (~50-100 eventos), relatos scrapeados (~4000+). Comparación de estrategias: Modelo A (pre-entrenado Suiza + fine-tuning Chile), Modelo B (desde cero solo Chile), Modelo C (transfer sin NLP), Modelo D (transfer con NLP). Validación cruzada temporal 2018-2024. Criterios: H3 - Modelo A supera B por ≥5pp; H2 - Modelo D supera C por ≥5pp.

Fase 3 - Comparación con Snowlab La Parva: Recopilación de pronósticos históricos Snowlab (2024-2025), mapeo a Escala Europea, ejecución retrospectiva del sistema, comparación cuantitativa (concordancia 5 niveles, Cohen's Kappa, discrepancias en días críticos) y cualitativa (factores identificados, claridad comunicacional). Criterio H4: concordancia ≥75% (Kappa ≥0.60).

Fase 4 - Piloto Operacional (Invierno 2026): Despliegue en zona piloto la parva, generación diaria de boletines usando infraestructura serverless existente, recolección de observaciones de campo, encuestas de utilidad percibida, análisis de costos operacionales (validación de escalabilidad económica), análisis de ablación (sistema completo vs. sin componentes específicos).

III. PLANIFICACIÓN DEL TRABAJO DEL PROYECTO

3.1 Objetivos específicos y tareas

1. Implementar la infraestructura para el proyecto GCP y Databricks
2. Desarrollar los cuatro agentes especializados (topográfico con PINNs, satelital con Vision Transformers, meteorológico integrando Google Weather API, integrador con NLP) sobre la infraestructura serverless y establecer pipeline de coordinación inter-agente event-driven.
3. Validar sistema con datos históricos SLF mediante transfer learning, comparar estrategias de entrenamiento, y evaluar contribución de componentes individuales mediante análisis de ablación.
4. Realizar comparación sistemática con pronósticos manuales Snowlab Chile, calculando concordancia cuantitativa y evaluando calidad cualitativa de boletines generados.

5. Desplegar piloto operacional durante invierno 2026 en zonas seleccionadas, generar boletines diarios mediante infraestructura serverless, recolectar feedback de usuarios, y validar escalabilidad económica.
6. Consolidar los aprendizajes y resultados obtenidos a lo largo del desarrollo de la investigación.

3.2 Metodología de trabajo

Desarrollo iterativo agile con sprints de 2 semanas sobre infraestructura existente, priorizando agentes de mayor impacto (topográfico y meteorológico primero). Validación cruzada continua con múltiples fuentes de verdad terreno (datos SLF, observaciones Snowlab, eventos documentados). Métricas cuantitativas primarias: F1-score macro por nivel EAWS, Precision/Recall, concordancia con expertos humanos, costos operacionales por ubicación monitoreada. Métricas cualitativas: completitud de factores explicativos identificados, claridad comunicacional de boletines, utilidad percibida por usuarios finales. Monitoreo continuo de costos mediante Cloud Billing para validar escalabilidad económica.

3.3 Plan de trabajo

Junio-Agosto 2025: Desarrollo Agente 1 (topográfico-nival con PINNs) y Agente 3 (meteorológico integrando Google Weather API sobre infraestructura serverless existente). Expansión de pipelines de integración de datos SRTM vía Google Earth Engine. Continuación de scraping sistemático de relatos.

Septiembre-Noviembre 2025: Desarrollo Agente 2 (satelital con Vision Transformers) integrando Google Earth Engine. Desarrollo Agente 4 (integrador con NLP) para extracción de conocimiento de ~4000+ relatos. Validación retrospectiva Fase 1 con datos suizos SLF.

Diciembre 2026: Despligue arquitectura y itegraciones de datos metereologicos, satelitales y relatos.

Enero 2025-Marzo 2026: Desarrollo agentes especializados.

Marzo 2025-Abril 2026: Fase 2 de validación con datos chilenos, experimentación de estrategias transfer learning, comparación con pronósticos Snowlab. Preparación de infraestructura serverless para despliegue piloto operacional. Validación de costos operacionales.

Abril-Mayo 2026: Refinamiento del sistema basado en validaciones previas. Selección y preparación de zonas piloto. Establecimiento de protocolos de recolección de feedback y observaciones de campo.

Junio-Agosto 2026: Fase 3 - Despliegue piloto operacional en invierno usando infraestructura serverless. Generación diaria de boletines, monitoreo continuo de desempeño y costos, recolección sistemática de observaciones y feedback de usuarios finales.

Agosto-septiembre 2026: Fase 4 Eevaluación integral de resultados incluyendo análisis económico de escalabilidad, redacción de informe final de tesina, preparación de defensa oral.

V. RECURSOS REQUERIDOS Y COMPROMISOS

Infraestructura Operacional Existente: Sistema snow_alert completamente implementado y operacional sobre Google Cloud Platform con arquitectura serverless. Componentes disponibles: Cloud Functions (extractor y procesador), Cloud Scheduler (ejecución cada hora), Pub/Sub, Cloud Storage, BigQuery y un workspace de databricks para el desarrollo de los flujos ageticos.

Recursos Tecnológicos Disponibles: Acceso a Google Earth Engine para procesamiento de datos SRTM y satelitales Sentinel-2, integración Google Weather API (condiciones actuales, pronósticos horarios hasta 240h, pronósticos diarios 10 días, históricos 24h), infraestructura computacional cloud para entrenamiento de modelos.

Datos y Validación: Base de datos históricos del Instituto Suizo SLF (disponible públicamente para investigación académica, 1999-2024), acceso a pronósticos históricos de Snowlab Chile para La Parva (periodo 2024-2025), corpus de ~4000+ relatos de montañistas desde Andeshandbook, datos de avalanchas documentadas en Chile por CONAF y otras fuentes (~50-100 eventos), datos meteorológicos en tiempo real desde Google Weather API.

Software y Librerías: PyTorch para implementación de PINNs y Vision Transformers, frameworks de NLP (spaCy, Transformers), XGBoost/SHAP para integración de riesgos y explicabilidad, LangChain para generación de boletines en lenguaje natural, GDAL/Google Earth Engine APIs para procesamiento geoespacial, Google Cloud SDK para gestión de infraestructura serverless.

REPOSITORIO PROYECTO

https://github.com/fpenailillo/snow_alert/

REFERENCIAS BIBLIOGRÁFICAS

[1] F. Techel, M. Bavay, and C. Pielmeier, "Data-driven automated predictions of the avalanche danger level for dry-snow conditions in Switzerland," Natural Hazards and Earth System Sciences, vol. 22, no. 6, pp. 2031-2056, 2022. [Online]. Disponible: https://nhess.copernicus.org/articles/22/2031/2022/

[2] A. Vaswani et al., "Attention is All You Need," in Advances in Neural Information Processing Systems, 2017, pp. 5998-6008. [Online]. Disponible: https://arxiv.org/abs/1706.03762

[3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," Journal of Computational Physics, vol. 378, pp. 686-707, 2019. [Online]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0021999118307125

[4] A. Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in International Conference on Learning Representations, 2021. [Online]. Disponible: https://arxiv.org/abs/2010.11929

[5] Google for Developers, "Weather API overview," Google Maps Platform, 2025. [Online]. Disponible: https://developers.google.com/maps/documentation/weather/overview

[6] Google Maps Platform, "Introducing the Google Maps Platform Weather API: Build weather-aware solutions for your users," April 2025. [Online]. Disponible: https://mapsplatform.google.com/resources/blog/introducing-the-google-maps-platform-weather-api-build-weather-aware-solutions/

[7] D. McClung and P. Schaerer, The Avalanche Handbook, 3rd ed., Seattle: The Mountaineers Books, 2006. [Online]. Disponible: https://www.mountaineers.org/books/books/the-avalanche-handbook-4th-edition

[8] R. Garreaud et al., "The Central Chile Mega Drought (2010-2018): A climate dynamics perspective," International Journal of Climatology, vol. 40, no. 1, pp. 421-439, 2020. [Online]. Disponible: https://rmets.onlinelibrary.wiley.com/doi/abs/10.1002/joc.6219

[9] J. Schweizer et al., "Review of spatial variability of snowpack properties and its importance for avalanche formation," Cold Regions Science and Technology, vol. 51, no. 2-3, pp. 253-272, 2008. [Online]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0165232X07000973

[10] G. Statham et al., "A conceptual model of avalanche hazard," Natural Hazards, vol. 90, no. 2, pp. 663-691, 2018. [Online]. Disponible: https://link.springer.com/article/10.1007/s11069-017-3070-5

[11] Snowlab Chile, "Servicios de pronóstico y consultoría en avalanchas," 2024-2025. [Online]. Disponible: https://www.snowlab.cl

[12] Agencia Estatal de Meteorología (AEMET), "La Guía de Aludes," Ministerio de Agricultura, Alimentación y Medio Ambiente, Madrid, España, 2015. [Online]. Disponible: https://doi.org/10.31978/281-15-009-X

[13] European Avalanche Warning Services (EAWS), "European Avalanche Danger Scale," 2023. [Online]. Disponible: https://www.avalanches.org/standards/avalanche-danger-scale/

[14] K. Müller, F. Techel, and C. Mitterer, "The EAWS matrix, a decision support tool to determine the regional avalanche danger level (Part A): conceptual development," Nat. Hazards Earth Syst. Sci., vol. 25, pp. 4503-4525, 2025. [Online]. Disponible: https://doi.org/10.5194/nhess-25-4503-2025

[15] G. Cheng, M. Morlighem, and S. Francis, "Forward and inverse modeling of ice sheet flow using physics-informed neural networks: Application to Helheim Glacier, Greenland," J. Geophys. Res. Mach. Learn. Comput., vol. 1, e2024JH000169, 2024. [Online]. Disponible: https://doi.org/10.1029/2024JH000169

[16] V. Steidl, J. L. Bamber, and X. X. Zhu, "Physics-aware machine learning for glacier ice thickness estimation: A case study for Svalbard," The Cryosphere, vol. 19, no. 2, pp. 645-661, 2025. [Online]. Disponible: https://doi.org/10.5194/c-19-645-2025

[17] J. Ma, H. Shen, Y. Cai, T. Zhang, J. Su, W.-H. Chen, and J. Li, "UCTNet with dual-flow architecture: Snow coverage mapping with Sentinel-2 satellite imagery," Remote Sensing, vol. 15, no. 17, art. 4213, Aug. 2023. [Online]. Disponible: https://doi.org/10.3390/rs15174213

[18] A. Melón-Nava, "Recent patterns and trends of snow cover (2000-2023) in the Cantabrian Mountains (Spain) from satellite imagery using Google Earth Engine," Remote Sensing, vol. 16, no. 19, art. 3592, Sep. 2024. [Online]. Disponible: https://doi.org/10.3390/rs16193592

[19] A. Avcıoğlu, O. Demir, and T. Görüm, "An automated approach for developing geohazard inventories using news: Integrating natural language processing (NLP), machine learning, and mapping," Nat. Hazards Earth Syst. Sci., vol. 25, pp. 2421-2435, Jul. 2025. [Online]. Disponible: https://doi.org/10.5194/nhess-25-2421-2025

[20] Y. Xie et al., "MARSHA: Multi-agent RAG system for hazard adaptation," npj Clim. Action, vol. 4, art. 70, Jul. 2025. [Online]. Disponible: https://doi.org/10.1038/s44168-025-00254-1

[21] A. Singh, N. Dhiman, K. C. Niraj, and D. P. Shukla, "Ensembled transfer learning approach for error reduction in landslide susceptibility mapping of the data scare region," Sci. Rep., vol. 14, art. 29060, Nov. 2024. [Online]. Disponible: https://doi.org/10.1038/s41598-024-76541-4

[22] A. Maissen, F. Techel, and M. Volpi, "A three-stage model pipeline predicting regional avalanche danger in Switzerland (RAvaFcast v1.0.0): A decision-support tool for operational avalanche forecasting," Geosci. Model Dev., vol. 17, no. 21, pp. 7569-7593, Oct. 2024. [Online]. Disponible: https://doi.org/10.5194/gmd-17-7569-2024

[23] C. Pérez-Guillén, F. Techel, M. Volpi, and A. van Herwijnen, "Assessing the performance and explainability of an avalanche danger forecast model," Nat. Hazards Earth Syst. Sci., vol. 25, pp. 1331-1351, Apr. 2025. [Online]. Disponible: https://doi.org/10.5194/nhess-25-1331-2025

[24] K.-U. Eiselt and R. G. Graversen, "Predicting avalanche danger in northern Norway using statistical models," The Cryosphere, vol. 19, pp. 1849-1871, May 2025. [Online]. Disponible: https://doi.org/10.5194/tc-19-1849-2025

[25] L. Viallon-Galinier, P. Hagenmuller, and N. Eckert, "Combining modelled snowpack stability with machine learning to predict avalanche activity," The Cryosphere, vol. 17, no. 6, pp. 2245-2260, Jun. 2023. [Online]. Disponible: https://doi.org/10.5194/tc-17-2245-2023

[26] A. J. Dietz et al., "Snow cover trends in the Chilean Andes derived from 39 years of Landsat data and a projection for the year 2050," Remote Sensing, vol. 17, no. 9, art. 1651, May 2025. [Online]. Disponible: https://doi.org/10.3390/rs17091651