Sistema Inteligente de Predicción de Riesgo de Avalanchas para Chile: Boletines de Seguridad Zonales mediante Coordinación de Agentes de IA Especializados

Estudiante: Francisco Peñailillo - **Profesor Guía Propuesto:** Dr. Mauricio Solar

Programa: Magíster en Tecnologías de la Información - USM

RESUMEN

En Chile, miles de personas se enfrentan al riesgo de avalanchas sin contar con sistemas de predicción avanzados como en países desarrollados, donde se alcanzan precisiones del 74–78% con hasta 72 horas de anticipación. Actualmente, el monitoreo y control de riesgos en el país depende de patrullajes manuales, lo que limita la cobertura y la capacidad de respuesta.

Se propone el desarrollo del primer sistema nacional inteligente de predicción de riesgos de avalanchas, basado en una arquitectura de sistemas multi-agentes. Cuatro agentes de IA especializados procesarán datos topográficos, modelos meteorológicos de nieve, relatos de montañistas y conocimiento experto. El sistema generará pronósticos automatizados según la Escala Europea de Peligro de Aludes, con boletines zonales de 24 a 72 horas.

La validación se realizará mediante comparación con datos históricos del Instituto Suizo SLF, pronósticos manuales de Snowlab Chile y pruebas en terreno durante el invierno de 2026. El objetivo es alcanzar una precisión superior al 75% en la predicción del riesgo de avalancha en las zonas de estudio.

Palabras clave: Sistemas Big Data, Deep Learning, Sistemas multi-agente, Análisis predictivo de series de tiempo, Predicción de riesgo de avalanchas.

1. PROBLEMA Y PROPUESTA DE SOLUCIÓN

1.1 Definición Técnica del Problema

El problema se define como predicción multi-modal de series temporales en ambiente geoespacial especifico a gran escala, con tres subproblemas interrelacionados:

Subproblema 1 - Integración de datos heterogéneos: Fusionar fuentes con diferentes resoluciones espaciales (SRTM 30m, satelital 10-250m), temporales (observaciones puntuales vs. predicciones 12 días) y naturaleza (estructurados: meteorología; semi-estructurados: relatos; geoespaciales: DEM). Requiere sincronización temporal, normalización espacial y extracción de features desde fuentes no estructuradas.

Subproblema 2 - Modelado predictivo con datos escasos: Las avalanchas son eventos raros en territorio extenso, generando datasets altamente desbalanceados. Chile carece de registros históricos sistemáticos, requiriendo estrategias de transfer learning desde regiones con datos abundantes (Suiza, Canadá) hacia condiciones chilenas únicas (clima continental, influencia ENSO, capas débiles persistentes).

Subproblema 3 - Pronósticos explicables y zonales: Los usuarios (guardaparques, operadores, autoridades) requieren comprensión de factores causales y zonificación espacial precisa, demandando capacidades de explicabilidad y generación

automatizada de boletines en lenguaje natural.

Contexto Nacional: Chile presenta un vacío crítico en infraestructura predictiva, acotada a iniciativas puntuales en algúnos centros de ski y mineria. Snowlab, iniciativa privada desde 2024, genera pronósticos manuales únicamente para La Parva compartiendo sus resultados a la comunidad, dejando sin cobertura a gran parte del territorio cordillerano. Esta dependencia de análisis manual limita escalabilidad territorial, consistencia metodológica y capacidad de respuesta ante múltiples zonas simultáneamente en riesgo.

1.2 Estrategia de Solución

La solución adopta especialización coordinada mediante arquitectura multi-agente, donde cada agente desarrolla expertise en un dominio específico:

Agente 1 - Análisis Topográfico-Nival: Procesa datos SRTM para identificar zonas con pendientes críticas (30-45°) y segmentación altitudinal (<2.500m, 2.500-3.200m, 3.200-3.500m, >3.500m). Aplica Physics-Informed Neural Networks (PINNs) para modelar evolución del manto considerando variación térmica por altitud. Output: mapa de susceptibilidad base + estado estimado del manto estratificado por altitud. Tecnologías: Google Earth Engine, GDAL, PyTorch (PINNs).

Agente 2 - Monitoreo Satelital: Emplea Vision Transformers pre-entrenados (ViT-Base/16) fine-tuned en imágenes nivales para análisis temporal de series Sentinel-2 (10m). Detecta cambios en cobertura, características superficiales indicativas de inestabilidad y correlaciona con zonas susceptibles. Output: anomalías detectadas, nivel de alerta. Tecnologías: Google Earth Engine, timm (PyTorch).

Agente 3 - Predicción Meteorológica: Integra pronósticos de precipitación, temperatura, isoterma 0°C por rango altitudinal y vientos desde modelos como snowforecast usando Time-LLM o LSTM. Identifica ventanas temporales de precipitación excesiva (>30cm/24h) que gatillan avalanchas. Output: probabilidades de condiciones gatillantes por horizonte y banda altitudinal. Tecnologías: Time-LLM [5], APIs.

Agente 4 - Integración de Riesgos: Fusiona outputs anteriores con patrones históricos extraídos de relatos (NLP) para clasificación según Escala Europea de Peligro de Aludes (5 niveles: 1-Débil, 2-Limitado, 3-Notable, 4-Fuerte, 5-Muy Fuerte). Extrae factores explicativos y genera boletines automatizados siguiendo estructura SLF/AEMET [1, 13] con lenguaje natural. Output: pronósticos zonales 24h/48h/72h con niveles de confianza. Tecnologías: XGBoost, SHAP, LangChain, LIms.

Flujo de Coordinación: Los agentes operan en pipeline secuencial con retroalimentación: agente topográfico identifica zonas susceptibles (constante), agentes satelital y meteorológico proporcionan condiciones actuales/proyectadas (dinámico), y agente integrador sintetiza información produciendo pronósticos con niveles de confianza asociados.

1.3 Principales Componentes de TI

Adquisición de Datos Geoespaciales: SRTM DEM (30m), Google Earth Engine para imágenes satelitales, APIs meteorológicas.

Extracción de Conocimiento No Estructurado: Web scraping distribuido de relatos de montañistas, NLP para identificación de patrones de riesgo, Named Entity Recognition geográfica.

Machine Learning: PINNs para modelado híbrido físico-estadístico, Vision Transformers para análisis temporal satelital, Time-LLM/LSTM para predicción meteorológica, XGBoost/Random Forests para clasificación de riesgo.

Sistemas Multi-Agente: LangChain o N8N para coordinación inter-agente para la generación conjunta y automatizada del boletin zonal.

Infraestructura: Cloud computing para procesamiento escalable, Modelos de IA y APIs REST para consumo de pronósticos y consumo de datos satelitales.

2. MARCO TEÓRICO Y ESTADO DEL ARTE

2.1 Marco Teórico

Ciencia de Avalanchas: La formación responde a interacción compleja de terreno, manto nival y meteorología [9]. En Chile, condiciones críticas se concentran en pendientes 30-45° y altitudes 2.500-3.500 msnm donde la isoterma 0°C fluctúa generando ciclos de derretimiento-recongelamiento [6, 7, 13]. La estabilidad del manto depende de formación de capas débiles persistentes bajo gradientes térmicos intensos [8, 9]. Los aludes se clasifican en: nieve reciente (densidad <200 kg/m³), placa (200-400 kg/m³) y nieve húmeda (350-500 kg/m³) [12].

Sistemas Multi-Agente (MAS): Paradigma arquitectural donde agentes autónomos especializados colaboran para resolver problemas que exceden capacidades de sistemas monolíticos [2]. La especialización permite expertise focalizado mientras la coordinación habilita síntesis de información complementaria.

Physics-Informed Neural Networks (PINNs): Integran principios físicos conocidos como restricciones en función de pérdida de redes neuronales [3]. Para modelado nival, incorporan ecuaciones de conservación de energía, leyes de metamorfosis y mecánica de materiales, reduciendo requerimientos de datos empíricos mientras mantienen consistencia física.

Vision Transformers (ViT): Revolucionaron análisis de imágenes mediante mecanismos de self-attention [2, 4]. Capturan dependencias de largo alcance espacial y temporal, crítico para detectar patrones evolutivos en secuencias satelitales y correlacionar características distantes espacialmente.

Transfer Learning: Ante carencia de registros chilenos sistemáticos, permite aprovechar conocimiento desde dominios ricos en datos (Swiss SLF, Canadian Avalanche Centre) mediante fine-tuning de modelos pre-entrenados [4]. La hipótesis fundamental es que patrones de bajo nivel (texturas nivales, firmas espectrales) son transferibles inter-regionalmente.

2.2 Estado del Arte

Sistemas Operacionales: El Instituto Suizo SLF alcanza 74-78% de precisión equiparable a pronosticadores expertos humanos, operando con 72h de anticipación mediante random forests sobre 50+ años de datos [1]. Limitaciones: enfoque monolítico sin modularidad, dependencia de infraestructura observacional costosa (>500 estaciones), adaptación regional limitada. Kazajstán tiene sistema con arquitectura similar [1]. Canadian Avalanche Centre emplea combinación de modelos numéricos con validación humana.

Iniciativa Nacional Chilena - Snowlab: Desde 2024 opera el primer servicio estructurado en Chile para La Parva mediante

pronósticos semanales por profesionales certificados con observaciones de campo sistemáticas [11]. Fortalezas: expertise humano local adaptado, validación continua, credibilidad con stakeholders. Limitaciones críticas: escalabilidad territorial nula (cobertura ~5km²), costo operacional, inconsistencia inter-regional, capacidad limitada (1 profesional → 1-2 zonas/día). La propuesta no busca reemplazar el expertise humano sino complementarlo y extenderlo a regiones sin cobertura, estableciendo sistema nacional base.

Avances Recientes en IA: Vision Transformers demuestran superioridad sobre CNNs en clasificación de imágenes [4], con aplicaciones recientes en monitoreo ambiental detectando cambios sutiles. Time-LLM reutiliza Large Language Models pre-entrenados para predicción temporal alcanzando mejores resultados en benchmarks meteorológicos [5]. PINNs demuestran efectividad en modelado de procesos hidro-glaciológicos donde datos son escasos pero física es bien comprendida [3].

Datos Geoespaciales: SRTM proporciona DEM globales 30m, empleado extensivamente en análisis de susceptibilidad. Snowforecast ofrece predicciones hasta 12 días mediante ensambles de modelos globales. Google Earth Engine democratiza procesamiento de petabytes de datos satelitales permitiendo análisis temporal retrospectivo sin infraestructura local. Servicios como AEMET y SLF publican boletines nivológicos diarios durante temporada invernal empleando Escala Europea de Peligro de Aludes [1, 11, 13, 14]. El SLF opera el sistema más avanzado globalmente con >80 años de experiencia y bases de datos desde 1936.

Brecha Identificada: No existe implementación documentada de arquitectura multi-agente coordinada para predicción de avalanchas que integre análisis topográfico automatizado, extracción de conocimiento comunitario y predicción a gran escala en latinoamerica.

2.3 Fuentes de Información

Primarias: Datos SRTM (NASA Earth Data), imágenes Sentinel-2/Landsat (Google Earth Engine), predicciones meteorológicas (snowforecast, ECMWF), datos de validación internacional (Swiss Avalanche Database SLF), datos de validación nacional (pronósticos históricos Snowlab La Parva 2024-2025), relatos de montañistas, boletines operacionales de referencia (AEMET España).

Secundarias: Artículos científicos revisados por pares, guías técnicas (La Guía de Aludes AEMET [12], The Avalanche Handbook [6]), documentación frameworks ML, reportes institucionales (WMO, UNDRR, CONAF), Escala Europea de Peligro de Aludes (EAWS).

3. PROPUESTA DE SOLUCIÓN E HIPÓTESIS

3.1 Especificación Técnica

Arquitectura del Sistema: Pipeline de 4 agentes especializados operando en secuencia coordinada.

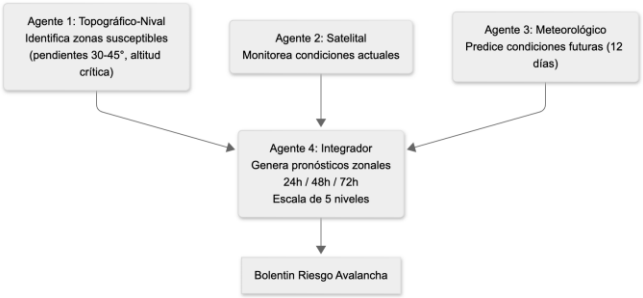

Escala de Riesgo: Se emplea la Escala Europea de Peligro de Aludes, desarrollada y estandarizada por EAWS, utilizada en todos

los países alpinos con >30 años de refinamiento operacional [1, 13, 14]. Caracteriza cada nivel mediante: (1) estabilidad del manto nivoso, (2) probabilidad de desencadenamiento (espontáneo vs. sobrecarga débil/fuerte), (3) distribución y tamaño. Los 5 niveles son: **(1) Débil** - manto bien estabilizado, solo aludes en terreno muy desfavorable con sobrecargas fuertes; **(2) Limitado** - manto moderadamente estabilizado en algunas laderas; **(3) Notable** - manto entre moderada y débilmente estabilizado en muchas laderas, sobrecarga débil puede desencadenar; **(4) Fuerte** - manto débilmente estabilizado en mayoría de laderas, aludes naturales probables; **(5) Muy Fuerte** - manto muy inestable, numerosos aludes grandes espontáneos esperables. Esta estandarización permite comparabilidad directa con datos históricos SLF [1] y facilita transferencia de conocimiento.

Pipeline de Datos: (1) Preprocesamiento topográfico: descarga tiles SRTM cordillera chilena (32°-55°S), generación de mapa de pendientes, segmentación altitudinal en 4 bandas, zonificación operacional. (2) Ingesta continua: consulta APIs meteorológicas (actualización 6h), descarga imágenes satelitales, actualización corpus de relatos. (3) Inferencia predictiva: ejecución diaria 06:00AM de 4 agentes secuencialmente, generación de pronósticos multi-horizonte, publicación de boletines automatizados. (4) Retroalimentación: validación post-temporada con avalanchas observadas, reentrenamiento con datos actualizados.

Integración de Conocimiento Experto: El scraping de relatos proporciona conocimiento tácito invaluable: identificación de zonas de mayor actividad, patrones específicos de acumulación/viento por ubicación, validación temporal correlacionando condiciones reportadas con avalanchas observadas, terminología para boletines comprensibles. Procesamiento NLP: Named Entity Recognition para extracción de ubicaciones geográficas, clasificación de sentimiento/urgencia, embedding de relatos en espacio vectorial para similaridad semántica.

3.2 Hipótesis de Investigación

H1 (Principal): "Un sistema multi-agente que integra análisis topográfico automatizado (SRTM), monitoreo satelital (Vision Transformers), predicción meteorológica (Time-LLM) y conocimiento experto extraído de relatos (NLP), puede generar pronósticos de riesgo de avalanchas para Chile clasificados según la Escala Europea de Peligro de Aludes (5 niveles) con precisión superior al 75% (F1-score macro) en horizontes de 24-72 horas, equiparando el desempeño de sistemas operacionales de países desarrollados (Suiza SLF: 74-78% [1])."

H2 (Secundaria): "La incorporación de conocimiento experto extraído de relatos de montañistas chilenos mediante técnicas de NLP mejora significativamente (>5 puntos porcentuales en F1-score) la precisión de predicción comparado con sistemas basados únicamente en datos observacionales estructurados."

H3 (Transferibilidad): "Un modelo entrenado mediante transfer learning desde datos históricos del Instituto Suizo SLF (20 años, >1000 eventos) y fine-tuned con datos chilenos limitados, supera el desempeño de un modelo entrenado exclusivamente con datos chilenos escasos."

H4 (Equiparación con Expertise Humano): "El sistema automatizado alcanza concordancia ≥80% con pronósticos manuales generados por profesionales certificados (Snowlab Chile) en la misma zona geográfica (La Parva), cuando ambos emplean la Escala Europea de Peligro de

Aludes, demostrando capacidad de replicar juicio experto sin presencia física continua."

3.3 Variables de la Investigación

Variables Independientes (Causales): (1) Arquitectura del sistema: multi-agente vs. monolítica. (2) Fuentes de datos integradas: topografía SRTM, satelital, meteorología, relatos NLP (presente/ausente). (3) Horizonte temporal: 24h, 48h, 72h. (4) Estrategia de entrenamiento: transfer learning vs. desde cero. (5) Zona geográfica: sectores cordilleranos (33°S-41°S).

Variables Dependientes (Observables): (1) Precisión del modelo: Precision, Recall, F1-score macro por nivel (1-Débil, 2-Limitado, 3-Notable, 4-Fuerte, 5-Muy Fuerte), accuracy por dimensión (estabilidad, probabilidad, distribución/tamaño), AUC-ROC, matriz de confusión 5x5, curvas de calibración. (2) Desempeño temporal: degradación por horizonte (24h→72h), lead time efectivo, estabilidad de predicción. (3) Cobertura territorial: porcentaje de zonas con pronósticos, resolución espacial efectiva. (4) Explicabilidad: completitud de factores vs. escala estándar europea, concordancia de recomendaciones, claridad comunicacional.

Variables de Control: Período temporal de análisis (temporadas 2015-2024), criterios de validación (umbrales de precipitación, tamaños de avalancha), calidad de datos (filtrado de imágenes nubosas, gaps meteorológicos).

3.4 Estrategia de Validación

Fase 1 - Validación Retrospectiva con Datos Suizos (Benchmarking): Objetivo: demostrar que arquitectura alcanza desempeño equiparable a sistemas establecidos con datos de alta calidad. Método: replicar pipeline usando SRTM Alpes Suizos, datos meteorológicos SLF (1999-2024), base de datos ~1200 eventos, relatos suizos (si disponibles). División temporal: entrenamiento 1999-2019, validación 2020-2022, test 2023-2024. Métricas: F1-score macro por horizonte vs. sistema SLF [1], análisis casos críticos, curvas precision-recall. Criterio de éxito H1: F1-score macro ≥0.75 en 24h, ≥0.72 en 48h, ≥0.68 en 72h. Accuracy en niveles críticos (3-Notable/4-Fuerte/5-Muy Fuerte) ≥0.80.

Fase 2 - Validación con Datos Chilenos (Transfer Learning): Objetivo: demostrar capacidad de transfer learning con datos escasos. Método: construir dataset chileno (topografía SRTM 33°-41°S, meteorología histórica CONAF/DMC/estaciones, avalanchas documentadas ~50-100 eventos, relatos scrapeados ~4000+). Estrategias comparativas: Modelo A (pre-entrenado Suiza, fine-tuned Chile 30%), Modelo B (desde cero solo Chile 100%), Modelo C (transfer sin NLP), Modelo D (transfer con NLP). Validación cruzada temporal (2018-2024). Criterios de éxito: H3 - Modelo A supera B por ≥5pp en F1-score; H2 - Modelo D supera C por ≥5pp.

Fase 2 - Benchmarking con Snowlab (La Parva): Objetivo: comparar automatizado contra profesionales humanos en condiciones chilenas. Método: recopilar pronósticos históricos Snowlab (2024-2025), mapear a Escala Europea, ejecutar sistema retrospectivamente, comparación cuantitativa (concordancia 5 niveles, Cohen's Kappa, discrepancias en días críticos, lead time) y cualitativa (factores identificados, claridad comunicacional, completitud). Criterio de éxito H4: concordancia ≥80% (Kappa ≥0.70), anticipación equivalente/superior en eventos críticos.

Fase 3 - Validación Operacional en Terreno (Invierno 2026): Objetivo: evaluar desempeño en condiciones reales. Método: despliegue piloto en 2-3 zonas (centro de esquí con infraestructura, parque nacional con

guardaparques, zona backcountry con comunidad montañistas). Protocolo: generación diaria de boletines, recolección de observaciones de campo, encuestas de utilidad percibida.

Fase 4 - Análisis de componentes: Método: experimentos sistemáticos removiendo componentes (sistema completo vs. sin agente satelital/topográfico/relatos NLP), análisis de importancia de features, evaluación de boletines (completitud de factores vs. conocimiento experto, claridad comunicacional).

CONCLUSIONES

Este proyecto propone una solución innovadora al problema crítico de ausencia de sistemas de predicción de avalanchas en Chile mediante una arquitectura multi-agente que integra tecnologías emergentes de IA con conocimiento experto local. La principal innovación radica en la combinación de cuatro agentes especializados que procesan datos heterogéneos (topográficos SRTM, satelitales, meteorológicos y conocimiento comunitario extraído mediante NLP) para generar pronósticos automatizados según estándares internacionales (Escala Europea de Peligro de Aludes).

La viabilidad técnica se sustenta en tres pilares: (1) transfer learning desde datos abundantes del SLF suizo hacia el contexto chileno con datos escasos, (2) validación multi-nivel que incluye benchmarking internacional, comparación con expertise humano local (Snowlab) y pruebas operacionales en terreno, y (3) arquitectura modular escalable que permite cobertura territorial nacional sin crecimiento lineal de costos operacionales.

El impacto esperado trasciende lo tecnológico: democratizar el acceso a información crítica de seguridad para comunidades cordilleranas, equipos de rescate, administradores de parques y deportistas, transformando la gestión reactiva actual hacia prevención inteligente. Con precisión objetivo superior al 75% en horizontes de 24-72 horas, el sistema busca equiparar capacidades de países desarrollados, posicionando a Chile como pionero hemisférico en aplicación de IA para gestión de riesgos naturales en montaña.

REFERENCIAS BIBLIOGRÁFICAS

[1] F. Techel, M. Bavay, and C. Pielmeier, "Data-driven automated predictions of the avalanche danger level for dry-snow conditions in Switzerland," Natural Hazards and Earth System Sciences, vol. 22, no. 6, pp. 2031-2056, 2022, doi: 10.5194/nhess-22-2031-2022. [Online]. Disponible: https://nhess.copernicus.org/articles/22/2031/2022/

[2] A. Vaswani et al., "Attention is All You Need," in Advances in Neural Information Processing Systems, 2017, pp. 5998-6008. [Online]. Disponible: https://arxiv.org/abs/1706.03762

[3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," Journal of Computational Physics, vol. 378, pp. 686-707, 2019, doi: 10.1016/j.jcp.2018.10.045. [Online]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0021999118307125

[4] A. Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in International Conference on Learning Representations, 2021. [Online]. Disponible: https://arxiv.org/abs/2010.11929

[5] M. Jin et al., "Time-LLM: Time Series Forecasting by Reprogramming Large Language Models," in International Conference on Learning Representations, Vienna, Austria, 2024. [Online]. Disponible: https://arxiv.org/abs/2310.01728

[6] D. McClung and P. Schaerer, The Avalanche Handbook, 3rd ed., Seattle: The Mountaineers Books, 2006, ISBN: 978-0898868098. [Online]. Disponible: https://www.mountaineers.org/books/books/the-avalanche-handbook-4th-edition

[7] R. Garreaud, J. P. Boisier, R. Rondanelli, A. Montecinos, H. H. Sepulveda, and D. Veloso-Aguila, "The Central Chile Mega Drought (2010-2018): A climate dynamics perspective," International Journal of Climatology, vol. 40, no. 1, pp. 421-439, 2020, doi: 10.1002/joc.6219. [Online]. Disponible: https://rmets.onlinelibrary.wiley.com/doi/abs/10.1002/joc.6219

[8] J. Schweizer, M. Kronholm, J. B. Jamieson, and K. W. Birkeland, "Review of spatial variability of snowpack properties and its importance for avalanche formation," Cold Regions Science and Technology, vol. 51, no. 2-3, pp. 253-272, 2008, doi: 10.1016/j.coldregions.2007.04.009. [Online]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0165232X07000973

[9] G. Statham et al., "A conceptual model of avalanche hazard," Natural Hazards, vol. 90, no. 2, pp. 663-691, 2018, doi: 10.1007/s11069-017-3070-5. [Online]. Disponible: https://link.springer.com/article/10.1007/s11069-017-3070-5

[10] M. Techel et al., "On the correlation between a sub-level qualifier refining the danger level with observations and models relating to the contributing factors of avalanche danger," Natural Hazards and Earth System Sciences, vol. 22, no. 6, pp. 1911-1930, 2022, doi: 10.5194/nhess-22-1911-2022.

[11] Snowlab Chile, "Servicios de pronóstico y consultoría en avalanchas," 2024-2025. [Online]. Disponible: https://www.snowlab.cl (Consultado: Oct. 2025).

[12] Agencia Estatal de Meteorología (AEMET), "La Guía de Aludes," Ministerio de Agricultura, Alimentación y Medio Ambiente, Madrid, España, 2015, NIPO: 281-15-009-X. [Online]. Disponible: https://doi.org/10.31978/281-15-009-X

[13] European Avalanche Warning Services (EAWS), "European Avalanche Danger Scale," 2023. [Online]. Disponible: https://www.avalanches.org/standards/avalanche-danger-scale/

ANEXO 1: ACRÓNIMOS Y ABREVIATURAS

AEMET - Agencia Estatal de Meteorología (España)
API - Application Programming Interface (Interfaz de Programación de Aplicaciones)
AUC-ROC - Area Under the Curve - Receiver Operating Characteristic
CNN - Convolutional Neural Network (Red Neuronal Convolucional)
CONAF - Corporación Nacional Forestal (Chile)
DEM - Digital Elevation Model (Modelo Digital de Elevación)
DMC - Dirección Meteorológica de Chile
EAWS - European Avalanche Warning Services (Servicios Europeos de Alerta de Avalanchas)
ECMWF - European Centre for Medium-Range Weather Forecasts
ENSO - El Niño-Southern Oscillation (El Niño-Oscilación del Sur)
GDAL - Geospatial Data Abstraction Library
IA - Inteligencia Artificial
LSTM - Long Short-Term Memory
MAS - Multi-Agent System (Sistema Multi-Agente)
ML - Machine Learning (Aprendizaje Automático)
NLP - Natural Language Processing (Procesamiento de Lenguaje Natural)
PINNs - Physics-Informed Neural Networks (Redes Neuronales Informadas por la Física)
SLF - Swiss Federal Institute for Snow and Avalanche Research (Instituto Federal Suizo para la Investigación de Nieve y Avalanchas)
SRTM - Shuttle Radar Topography Mission
ViT - Vision Transformer
XAI - Explainable Artificial Intelligence (Inteligencia Artificial Explicable)

ANEXO 2: DESARROLLOS TÉCNICOS BASE REALIZADOS EN Q3

Durante el último trimestre, he avanzado en la exploración y aplicación de tecnologías clave para el desarrollo del sistema propuesto. Logré acceso a recursos de datos geoespaciales de alta calidad como NASA Earth Data (SRTM) y Copernicus (Unión Europea), y adquirí habilidades fundamentales en: programación en JavaScript, manejo de formatos geoespaciales como GeoJSON.

A continuación, se detallan los principales desarrollos técnicos que servirán como base para los agentes del sistema:

1. Análisis Topográfico de Pendientes con SRTM

Se realizó la conexión y análisis del proyecto **SRTM**, que monitorea los relieves del planeta. Utilizando la capacidad de cómputo de **Google Earth Engine**, se extrajeron y modelaron zonas montañosas con pendientes críticas entre **30° y 45°**, rango asociado a alta susceptibilidad de avalanchas.

Este análisis permitió: Detectar zonas de riesgo específicas en la Región Metropolitana y otras áreas cordilleranas, generar mapas de pendientes y segmentación altitudinal y estimar parámetros clave como orientación, altitud y gradiente térmico

Estos resultados constituyen la base para el **Agente 1: Topográfico-Nival**, encargado de identificar zonas susceptibles.

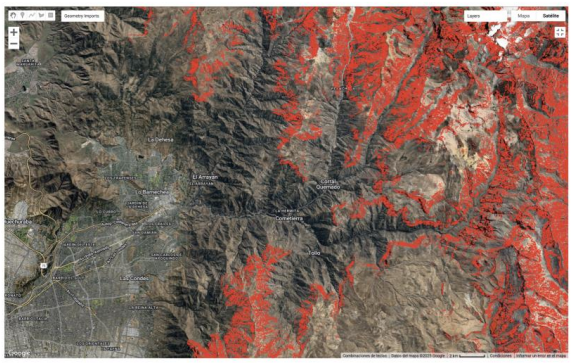

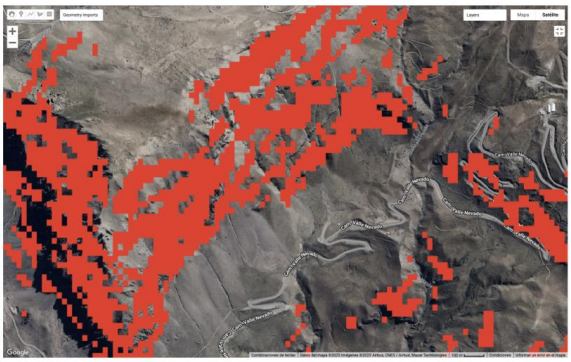

Análisis pendientes a gran escala RM con datos satelitales Análisis pendientes en un lugar conocido como riesgoso

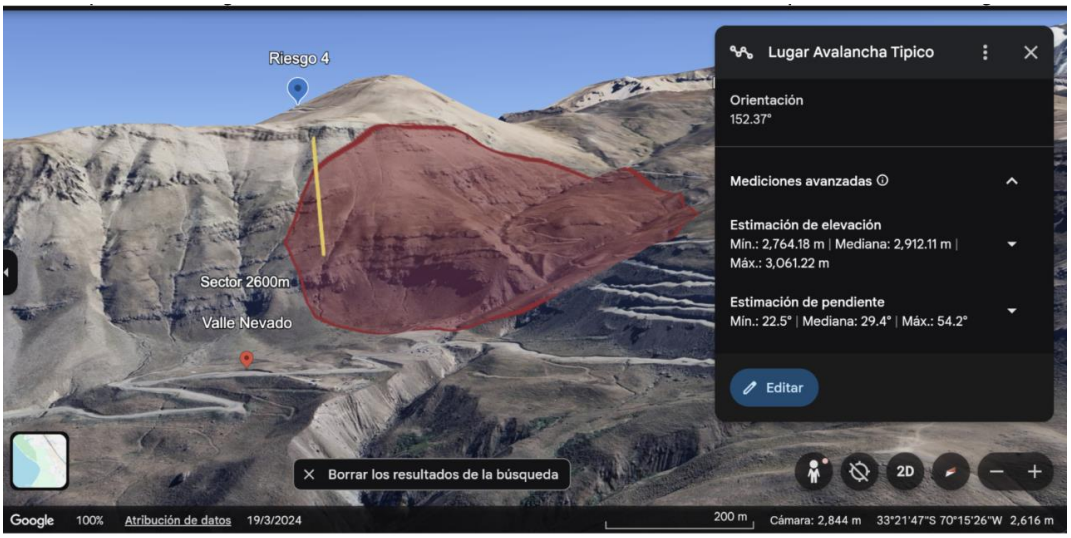

2. Análisis NLP de Relatos de Montañistas

En el contexto del proyecto de la asignatura de análisis de redes sociales, se analizaron más de 4.000 relatos provenientes de la plataforma Andeshandbook, aplicando técnicas de procesamiento de Lenguaje Natural (NLP) para extraer conocimiento experto comunitario.

El trabajo incluyó:

- Extracción de datos geográficos (latitud, longitud, sector, altitud)
- Identificación de patrones de riesgo y complejidad técnica
- Clasificación semántica de relatos según urgencia, tono y recomendaciones

El modelo de análisis organiza la información en **ocho categorías principales**:

1. **Resumen**: descripción general, tipo de actividad, puntos clave
2. **Ubicación**: montañas, valles, ciudades de acceso, altitud, región
3. **Características técnicas**: tipo de terreno, exposición, datos de ruta
4. **Condiciones temporales**: época recomendada, clima
5. **Equipamiento**: material técnico necesario
6. **Riesgos**: nivel de riesgo, factores críticos, experiencia requerida
7. **Aspectos emocionales**: tono, emociones predominantes, recomendaciones
8. **Metadatos**: calidad del análisis, palabras clave, fuentes

Este enfoque permite evaluar cada montaña desde una perspectiva técnica, geográfica, emocional y logística, generando un set de datos que será fundamental para el **Agente 4: Integrador de Riesgos**, que incorporará conocimiento experto en los boletines automatizados.

Estos dos módulos, el análisis topográfico de pendientes y el análisis semántico de relatos de montaña, constituyen pilares fundamentales para el desarrollo de los agentes especializados del sistema. Ambos permiten integrar datos estructurados y no estructurados en la arquitectura multi-agente, mejorando la precisión y explicabilidad de los pronósticos de riesgo de avalanchas.